

ELABORATO DATA MINING

A.A. 2024/2025

Costruzione Modello Lineare Robusto

Analisi Target Quantitativa & Binaria

■ Incidenti stradali a New York (2016–2023)

Gruppo di lavoro

Autore	Matricola
Alessia Acquaviva	888684
Ilaria Mato	882334
Pietro Meli	890726
Andrea Loffredo	885739

Abstract. Questo elaborato analizza un sottoinsieme del dataset US-Accidents (Kaggle) filtrato per lo stato di New York, con 8.448 osservazioni e 15 variabili. Vengono costruiti un **modello lineare robusto** per predire la visibilità stradale e un **modello logistico** per classificare il momento del giorno (Giorno/Notte) degli incidenti. La pipeline include pulizia dati, imputazione, verifica della collinearità, rilevamento di interazioni, trasformazioni, stepAIC, rimozione outlier, correzione dell'eteroschedasticità con stimatori di White e validazione Bootstrap.

1. Dataset

Il dataset scelto è **US-Accidents**, scaricato da **Kaggle** (Sobhan Moosavi et al.), e contiene le caratteristiche di incidenti stradali avvenuti in 49 dei 50 stati degli USA tra **febbraio 2016 e marzo 2023**.

Parametro	Valore originale	Dopo preprocessing
Osservazioni	7.730.000	8.448
Variabili	43	15
Stato	49 stati USA	New York (NY)
Periodo	Feb 2016 – Mar 2023	Feb 2016 – Mar 2023
Livelli City	477	125
Livelli Weather_Condition	47	11

1.1 Variabili

Dopo il filtraggio per stato NY e l'eliminazione delle colonne non pertinenti, le 15 variabili analizzate sono le seguenti:

Variabile	Tipo	Descrizione
Severity	Continua	Gravità dell'incidente (1–4)
Distance	Continua	Estensione stradale coinvolta (miglia)
City	Categoriale	Città dell'incidente (125 livelli)
Temperature	Continua	Temperatura in °F al momento dell'evento
Pressure	Continua	Pressione atmosferica (pollici)
Visibility ★	Continua	Target: visibilità in miglia
Wind_speed	Continua	Velocità del vento (mph)
Weather_Condition	Categoriale	Condizione meteo (11 livelli dopo raggruppamento)
Crossing	Binaria	Presenza di attraversamento pedonale (T/F)
Junction	Binaria	Presenza di incrocio (T/F)
Stop	Binaria	Presenza di segnale STOP (T/F)
Traffic_signal	Binaria	Presenza di semaforo (T/F)
Sunrise_Sunset	Categoriale	Giorno / Notte — usata come target binario
Month	Categoriale	Mese dell'anno (1–12)
Day	Categoriale	Giorno del mese (1–31)

★ Variabile target principale per il modello lineare.

1.2 Preprocessing delle variabili categoriali

City: le città con meno di 20 incidenti sono state raggruppate in "Altro" e successivamente eliminate. I livelli sono passati da **477** → **125**.

Weather_Condition: tramite *optimal grouping* con il pacchetto factorMerger (criterio GIC) i livelli sono stati ridotti da **47** → **11**.

2. Analisi dei Valori Mancanti

Le variabili che presentano dati mancanti sono state identificate tramite il pacchetto **VIM** (funzione `aggr`). L'imputazione scelta è la **imputazione singola con la media** per le variabili continue e con la **moda** per le categoriali.

Variabile	Tipo	Metodo di imputazione
wind_speed	Continua	Media (Hmisc::impute)
temperature	Continua	Media (Hmisc::impute)
pressure	Continua	Media (Hmisc::impute)
visibility	Continua	Media (Hmisc::impute)
Weather_Condition	Categoriale	Moda (Hmisc::impute)
Sunrise_Sunset	Categoriale	Moda (Hmisc::impute)

Dopo l'imputazione è stata verificata graficamente l'assenza residua di valori mancanti tramite un secondo plot `aggr`. Nessun NA è rimasto nel dataset finale.

3. Modello Lineare — Target: Visibility

La variabile target scelta per il modello lineare è **visibility** (visibilità in miglia), che permette di analizzare come le condizioni ambientali e infrastrutturali influenzino la visibilità durante gli incidenti, con possibili implicazioni per la segnaletica e la sicurezza stradale.

- 1

Modello iniziale (modello1)
Modello completo con tutte le 15 variabili. Variabili non significative rilevate: Severity, Crossing, Stop, Traffic_signal, Temperature, Sunrise_Sunset. $R^2 = 0.7573$ | AIC = 33.159,43.
- 2

Multicollinearità
Variabili quantitative: $VIF < 5$ e $TOL > 0.04 \rightarrow$ assenza di collinearità. Variabili qualitative: chi-quadro normalizzato < 0.80 per tutte le coppie $\rightarrow$ nessuna collinearità.
- 3

Interazioni (modello2)
L'interazione temperature $\times$ Sunrise_Sunset risulta significativa. AIC migliora da 33.159 $\rightarrow$ 33.153 | R^2 da 0.7573 $\rightarrow$ 0.7575.
- 4

Trasformazione Y — Box-Cox
Lambda suggerito = 1.67, ma la trasformazione peggiora AIC (33.153 $\rightarrow$ 64.090) e R^2 . Decisione: Y non trasformata.
- 5

Trasformazione X — GAM (modello4)
Loess e Spline suggeriscono forma cubica per distance e pressure. Applicate trasformazioni cubiche. RESET test: p-value $< 2.2e-16 \rightarrow$ trasformazioni altamente significative. $R^2 \rightarrow 0.7598$.
- 6

Model selection — stepAIC (modello5)
stepAIC (direction='both') seleziona il modello parsimonioso ottimale. Tutte le variabili diventano significative. AIC $\rightarrow 33.079$ | $R^2 = 0.7597$.
- 7

Rimozione Outlier — DFFITS (modello6)
Criterio: $|DFFITS| > 2\sqrt{(p/n)}$. Rimosse le osservazioni influenti. R^2 migliora drasticamente: 0.759 $\rightarrow$ 0.8506 | AIC $\rightarrow 26.673$.
- 8

Eteroschedasticità
ncvTest e bpTest confermano eteroschedasticità (p-value = $2.22e-16$). Soluzione: stimatori robusti di White (pacchetto sandwich, vcovHC).
- 9

Bootstrap (R = 1999)
Il Bootstrap conferma la robustezza dei parametri stimati. Il modello finale è stabile e robusto.

3.1 Riepilogo performance modelli

Modello	R^2	AIC	Note
---------	-------	-----	------

modello1 — completo	0.7573	33.159	Baseline
modello2 — + interazione	0.7575	33.153	temp × Sunrise_Sunset
modello4 — + cubiche	0.7598	33.083	distance ³ , pressure ³
modello5 — stepAIC	0.7597	33.079	Parsimonioso
modello6 — rimozione outlier	0.8506	26.673	Modello finale ✓

3.2 Formula del modello finale

Il modello finale (modello6 con stimatori di White) è definito come:

```
modello_final <- lm(
  visibility ~ distance + I(distance^2) + I(distance^3)
  + City
  + pressure + I(pressure^2) + I(pressure^3)
  + wind_speed + Weather_group + Severity
  + month + day
  + temperature * Sunrise_Sunset,
  data = b_filtered
)
```

$R^2 = 0.8506$ | $R^2_{adj} = 0.8357$ | AIC = 26.673,73

4. Modello Logistico — Target: Sunrise/Sunset (Giorno/Notte)

Nella seconda parte dell'analisi viene costruito un **modello logistico** per classificare se l'incidente è avvenuto di **giorno o di notte** (variabile *Sunrise_Sunset*).

4.1 Pipeline logistica

1 *Modello completo (logistico1)*

GLM con family=binomial su tutte le variabili disponibili. Variabili non significative: Junction, Traffic_signal, visibility.

2 *Model selection — stepAIC*

stepAIC seleziona modello_log2 con AIC = 10.127,52. Variabili nel modello: Severity, distance, City, Crossing, Junction, Stop, month, day, wind_speed, temperature, pressure, visibility, Weather_group.

3 *Confronto ANOVA (LRT)*

ANOVA tra logistico1 e modello_log2: p-value = 0.5994 > 0.05. Nessuna differenza significativa. Variazione devianza = -0.326. Il modello semplice si comporta in modo equivalente a quello completo.

4.2 Odds Ratio — Interpretazione

L'Odds Ratio misura l'associazione tra ciascun predittore e la probabilità che l'incidente avvenga di giorno (*Sunrise_Sunset* = Day):

Effetto	OR	Interpretazione
Amsterdam, Huntington Station, Fresh Meadows	~ 1	Aumentano fortemente la prob. di Day
Gruppo meteo 6	> 1	Aumenta la probabilità dell'evento
Hudson, Kirkville, Jordan	< 1	Associati a probabilità ridotta (Night)
Visibilità ridotta	< 1	Associata a incidenti notturni
Velocità del vento, Temperatura	≈ 1	Nessun effetto significativo

Interpretazione OR per variabili quantitative: per ogni unità di incremento, la probabilità di Day aumenta/diminuisce del fattore OR. **Per variabili qualitative:** la probabilità di Day è OR volte superiore/inferiore rispetto alla categoria di riferimento.

5. Pacchetti R Utilizzati

Pacchetto	Utilizzo
dplyr	Manipolazione e filtraggio del dataset
VIM	Visualizzazione e analisi dei valori mancanti
Hmisc	Imputazione dei missing values
factorMerger	Optimal grouping delle variabili categoriali
mctest	Calcolo VIF/TOL per la multicollinearità
psych	Pair panels per analisi esplorativa
gam	Modelli additivi generalizzati (Loess, Spline)
lmtest	RESET test e Breusch-Pagan test
MASS	stepAIC e trasformazione Box-Cox
car	ncvTest e Bootstrap (Boot)
sandwich	Stimatori robusti di White (vcovHC)

6. Istruzioni per la Replicazione

Per replicare l'analisi è necessario:

1. Scaricare il dataset US-Accidents dal sito Kaggle (link nella sezione Dataset).
2. Filtrare il dataset per State == 'NY' per ottenere il sottoinsieme di New York.
3. Impostare la working directory nel file DM_code.R con setwd().
4. Installare tutti i pacchetti elencati nella sezione precedente.
5. Eseguire lo script DM_code.R in sequenza: ogni blocco è commentato per guidare l'analisi.

Elaborato realizzato per il corso di Data Mining — A.A. 2024/2025

Dataset: US-Accidents (Sobhan Moosavi et al.) — Kaggle